

TECH CHALLENGE

FASE 3

Comportamento da população na época da pandemia da COVID-19

Tech Challenge é o projeto que englobará os conhecimentos obtidos em todas as disciplinas da fase

Agenda Tech Challenge

O problema do negócio

01

- O Head de Dados pediu para que o grupo entrasse na base de dados do PNAD-COVID-19 do IBGE e organizasse esta base para análise, utilizando Banco de Dados em Nuvem.
- Seu objetivo será trazer uma breve análise dessas informações, como foi a organização do banco.

02

Storytelling Técnico

- Arquitetura do pipeline e construção do modelo.
- Bases de saída (dimensão e temáticas).
- Tabelas fatos e dimensão.
- Fluxo de transformação.
- Chave de Identificação e peso amostral.

03

Resultado da Análise

- Comportamento dos sintomas.
- Comportamento da população.
- Comportamento econômico.
- Conclusões e recomendações.
- Análise refinadas.



O Problema do negócio

O Head de Dados pediu para que o grupo entrasse na base de dados do PNAD-COVID-19 do IBGE e organizasse esta base para análise, utilizando Banco de Dados em Nuvem e trazendo as seguintes características:

Requisitos:

- Utilização de no máximo 20 questionamentos realizados na pesquisa;
- Utilizar 3 meses para construção da solução;
- Caracterização dos sintomas clínicos da população;
- Comportamento da população na época da COVID-19;
- Características econômicas da Sociedade;

Dados: (<https://covid19.ibge.gov.br/pnad-covid/>)


Sobre o Desafio

Seu objetivo será trazer uma breve análise dessas informações, como foi a organização do banco, as perguntas selecionadas para a resposta do problema e quais seriam as principais ações que o hospital deverá tomar em caso de um novo surto de COVID-19.



Pipeline de construção do modelo

Este pipeline transforma os microdados brutos da **PNAD COVID-19 (IBGE)** em bases analíticas limpas, com variáveis renomeadas semanticamente e categorias traduzidas de código numérico para texto legível (ex.: 1 → "Homem", 2 → "Mulher").



Visão Geral

A pesquisa objetiva estimar o número de pessoas com sintomas referidos associados à síndrome gripal e monitorar os impactos da pandemia da COVID-19 no mercado de trabalho brasileiro



Período de Cobertura

Amostra: 193 mil domicílios por mês, painel fixo (as mesmas famílias são entrevistadas todos os meses, permitindo análise longitudinal)



Lógica do questionário

O questionário se divide em duas partes, sendo uma direcionada a questões de saúde, especificamente sobre sintomas associados à síndrome gripal e outra, a questões de trabalho.




Microdados

Microdados consistem no menor nível de desagregação dos dados de uma pesquisa, retratando, sob a forma de códigos numéricos, o conteúdo dos questionários, preservado o sigilo das informações. Os microdados possibilitam aos usuários, com conhecimento de linguagens de programação ou softwares de cálculo, criar suas próprias tabelas.

Arquitetura do Pipeline

Sobre o fluxo

O fluxo de transformação dos dados inicia com a captura de arquivos do IBGE relacionados à saúde, comportamento e economia. Os dados passam por um processo de ETL de refinamento, realizando limpeza, padronização e conversão para o formato Parquet. Depois, a etapa spec_to_trusted utiliza consultas SQL para gerar tabelas analíticas estruturadas. Por fim, os dados são apresentados em dashboards de Streamlit.



Bases de saída

As tabelas do projeto foram organizadas em dimensões e bases temáticas para facilitar análises sobre os impactos da pandemia. As dimensões armazenam informações de contexto, como perfil demográfico, localização, período da pesquisa e dicionário de variáveis, permitindo segmentar os dados por região, faixa etária, escolaridade e período. Já as bases temáticas concentram os dados analíticos principais, divididos em saúde, comportamento, economia e trabalho, trazendo informações sobre sintomas da COVID-19, uso de máscara, mercado de trabalho, renda, benefícios sociais, home office e vínculos empregatícios. Todas as tabelas podem ser relacionadas por chaves de identificação comuns, permitindo análises integradas e estratégicas sobre os efeitos da pandemia na população brasileira.

Para saber mais no detalhe acesse o arquivo Draw.io

[illegible]

Bases de saída

As dimensões descrevem os atributos de contexto de cada entrevistado. São a base para estratificar qualquer análise por perfil, localização ou tempo.

Dimensões

- ✓ DIM_TEMPO: Granularidade: 1 linha por combinação única de mês × número de entrevista.
- ✓ DIM_PERFIL: Perfil demográfico e escolar de cada morador. Todas as colunas categóricas já contêm o texto legível.
- ✓ DIM_LOCALIZACAO: Localização geográfica do domicílio.
- ✓ DIM_DICIONARIO: Catálogo de dados: documenta cada uma das 148 variáveis do pipeline. Não tem FK física — use para consulta de linhagem.

Temáticas

- ✓ BASE_SAUDE: sintomas clínicos, busca por atendimento, internação, testagem e comorbidades pré-existentes.
- ✓ BASE_COMPORTAMENTO: comportamentos adotados durante a pandemia — uso de máscara, busca por atendimento, situação no mercado de trabalho na semana da entrevista.
- ✓ BASE_ECONOMICO: renda efetiva recebida, auxílios governamentais, benefícios e vínculo empregatício.
- ✓ BASE_TRABALHO: características detalhadas do trabalho — tipo de ocupação, porte do empregador, formas de remuneração habitual e efetiva, home office, afastamento, busca por emprego.



Chave de Identificação

Todas as bases compartilham a mesma chave de 4 colunas que identifica univocamente uma pessoa em um mês:

```
uf + id_domicilio + id_morador + mes_entrevista
```

Use esta chave para cruzar qualquer base com outra (ex.: unir BASE_SAUDE com DIM_PERFIL para ver sintomas por faixa etária).

Peso Amostral

Regras Obrigatórias

A PNAD é uma amostra complexa. Nunca calcule percentuais ou médias sem ponderar pelo peso_amostral (coluna presente em todas as bases temáticas). Sem ponderação, os números representam apenas a amostra coletada, não o Brasil.


```
# Correto - % da população brasileira com febre na semana
(df_saude
 .groupBy('MES_REF')
 .agg(
   (F.sum(F.col('ind_teve_sintoma_gripal') * F.col('peso_amostral')) /
    F.sum('peso_amostral') * 100).alias('pct_sintoma')
 )
 .orderBy('MES_REF')
 .show())
```



Caracterização dos Sintomas


Analisa a prevalência de cada sintoma, a severidade (quantidade de sintomas), a testagem as comorbidades e o perfil demográfico dos sintomáticos

Pode-se notar a partir da caracterização dos sintomas que a faixa etária mais afetada é a partir dos 60 anos, com o sexo masculino tendo mais síndrome gripal e sendo a tosse o maior sintoma




Perfil dos sintomáticos (síndrome gripal)

Taxa de síndrome gripal por faixa etária




Taxa de síndrome gripal por sexo



Prevalência dos sintomas na população

Percentual da população que relatou cada sintoma




Comportamento da População

Analisa a adesão às medidas de proteção (isolamento social), a busca por atendimento, a situação no mercado de trabalho e o home office.

Pode-se notar que a maioria das pessoas (praticamente 50%) reduziu o contato e a busca por atendimento por síndrome gripal aumentou se comparado com a população geral


Nível de isolamento social por situação no mercado de trabalho (composição %)




Trabalhadores ocupados presencialmente são os que menos aderiram ao isolamento estrito.

Busca por atendimento de saúde

Busca por atendimento — geral vs. sintomáticos



Onde quem buscou atendimento foi atendido




Características Econômicas

Analisa a cobertura dos auxílios governamentais, a sobreposição de benefícios, a supressão de renda e a distribuição da renda do trabalho.


Pode-se notar que quase metade da população recebeu auxílio emergencial, além disso, nota-se que a região norte e nordeste ficam abaixo da média nacional em renda efetiva

Percentual da população que recebeu cada benefício



 Renda efetiva média por região

Renda efetiva média do trabalho principal por região




Conclusão e Recomendações

A partir dos três meses de análise (set/out/nov) de 2020, temos os seguintes macro números:

- Síndrome gripal (população): 2,2%
- Buscou atendimento (sintomáticos): 1,3%
- Ficou rigorosamente em casa: 13,3%
- Sem Renda efetiva: 62%

A partir das análises, recomenda-se:



Eixo 1 — Triage e Priorização Clínica

Ação	Fundamentação nos dados
Priorizar triagem de pacientes com febre + tosse combinadas	Sintomas mais prevalentes (0.8% e 1.4%) e co-ocorrentes nos 3 meses
Sinalizar alto risco em pacientes com dificuldade respiratória	Indicador de severidade clínica imediata
Criar protocolo acelerado para idosos com hipertensão ou diabetes	Comorbidades crescem rapidamente após os 45 anos
Usar perda de olfato/paladar como critério de isolamento imediato	Sintoma altamente específico da COVID-19
Marcar como alta prioridade todo sintomático com comorbidade	24.7% dos sintomáticos têm pelo menos uma comorbidade monitorada

Eixo 2 — Dimensionamento de Capacidade ↔

Indicador	Valor observado (3 meses)	Implicação
Busca por atendimento entre sintomáticos	1.3%	Estimar demanda real × capacidade instalada
Positividade entre testados	7.3%	Reservar leitos proporcionalmente
Síndrome gripal na população	2.2%	Base para previsão de fluxo de emergência
Evolução mensal	Queda de set → nov	Capacidade pode ser escalonada conforme a curva

Eixo 3 — Prevenção e Comunicação

Ação	Fundamentação nos dados
Incentivar permanência em casa na próxima onda	Apenas 13.3% ficou rigorosamente em casa; a maioria reduziu contato mas continuou saindo
Campanha focada em trabalhadores presenciais	Menor adesão ao isolamento estrito nesse grupo
Priorizar conscientização no Norte e Nordeste	Menor taxa de home office, maior exposição
Reforçar testagem precoce	Apenas 12.0% da população se testou no período

Conclusão e Recomendações

A partir dos três meses de análise (set/out/nov) de 2020, temos os seguintes macro números:

- Síndrome gripal (população): 2,2%
- Buscou atendimento (sintomáticos): 1,3%
- Ficou rigorosamente em casa: 13,3%
- Sem Renda efetiva: 62%


A partir das análises, recomenda-se:

Eixo 4 — Suporte Socioeconômico

Ação	Fundamentação nos dados
Mapear pacientes sem renda efetiva para suporte assistencial	62.0% dos entrevistados sem renda efetiva no mês
Articular o hospital com a rede de proteção social (CRAS, CREAS)	Dependência de Auxílio Emergencial em torno de 48.7%
Considerar fila para beneficiários de BF + AE (dupla vulnerabilidade)	Sobreposição expressiva entre os dois benefícios
Monitorar a queda do valor médio do auxílio ao longo dos meses	Redução da política pública agrava a vulnerabilidade

Eixo 5 — Ação Territorial

Ação	Fundamentação nos dados
Monitorar Norte e Nordeste : menor renda, menor home office, maior informalidade	Confluência de fatores de risco evidenciada no mapa de risco regional
Expandir testagem móvel em áreas rurais	Menor acesso a estabelecimentos de saúde
Integrar dados de localização para identificar clusters de alta positividade	A chave uf + id_domicilio permite análise geoespacial



Análise Refinada

Recomendamos para verificar toda a análise aprofundada feita a partir dos dados da PNAD, rodar o Streamlit disponível em `code/dashboard_analise_refinada.py` do [Github](https://github.com/naruto112/pnad_covid_fase3):
https://github.com/naruto112/pnad_covid_fase3 na branch main.

Neste Github consta todos os arquivos, o fluxo ETL e toda a análise final feita em Dataviz, utilizando a biblioteca do Streamlit.

No Readme.md é possível verificar como rodar de forma segura o Streamlit localmente.



Obrigado!

Alunos:

Arthur Batista Aragão

Marcus Vinicius da Silva Ferreira

Renato Moschetta de Souza

Comportamento da população na época da pandemia da COVID-19

Turma 12DTAT